

Laboratório de Fusão e
Inteligência Artificial Aplicada
(LaFIAA)

Introdução ao Aprendizado Não- Supervisionado




Instituto de Pesquisas
da Marinha

Prof. Pablo Rangel

*Encarregado da Divisão de Desenvolvimento, Operações e Qualidade
Coordenador do LaFIAA*

Aprendizado Supervisionado: limitações




Requer conhecimento a priori!


Limita as saídas para um conjunto pré-definido de respostas.

Extração de conhecimento limitada.

Problemas com explicabilidade.



Aprendizado Não - Supervisionado



Dados podem ser apresentados sem nenhum conhecimento a priori.



Grupos (ou *clusters*) são criados ao longo do tempo representando as entradas por grau de similaridade entre elas.




O aprendizado supervisionado é usualmente utilizado para processos de **agrupamento**.


Mapas Auto-Organizáveis de Kohonen (1982)

Na década de 1980, Teuvo Kohonen propôs um modelo matemático de aprendizado competitivo.

É chamado de Self-Organized Map (SOM)

Transforma um mapa multidimensional em um mapa bidimensional ($N \times M$ neurônios).






Representação de Entradas e Atributos

Entradas são um conjunto de atributos (a) que você deseja que uma rede neural aprenda.

Por exemplo, você gostaria de aprender sobre o perfil socioeconômico de uma população. A amostra pode ter como base o salário bruto e a idade.

Como estão em domínio de valores distintos, os atributos das amostras são convertidas para um intervalo entre 0 e 1

$$f(a) = \frac{valor - min}{max - min}$$



Representação de Entradas e Atributos

Seja Pessoa 1 x_1 e
Pessoa 2 x_2 .

x_1 possui 49 anos
e salário de R\$
20.000,00.

x_2 possui 24 anos
e salário de
R\$5.000,00.

Convertemos os
atributos
utilizando o
método Min-Max.

Seja 18 anos e 120
anos as idades
mínima e máxima.

Seja R\$1.200,00 e
R\$30.000,00 os
salários mínimo e
máximos.

$$X_1^{idade} = \frac{49-18}{120-18} = \frac{31}{102} \approx 0,30$$

$$X_1^{salario} = \frac{20000-1200}{30000-1200} = \frac{18800}{28800} \approx 0,65$$


$$X_1 = [0.3, 0.65]$$


$$X_2^{idade} = \frac{24-18}{120-18} = \frac{6}{102} \approx 0,05$$

$$X_2^{salario} = \frac{5000-1200}{30000-1200} = \frac{3800}{28800} \approx 0,13$$

$$X_2 = [0.05, 0.13]$$

Mapas Auto-Organizáveis de Kohonen: Algoritmo





Mapas Auto-Organizáveis de Kohonen: Inicialização dos pesos


Neurônio N é representado pelos pesos.

Requer vetor de pesos w com o quantitativo de valores para cada amostra existente.

A inicialização pode ser com valores pré-fixados ou por função randômica r .

Pré-fixado: $w_i = [0, 0, 0, 0]$.

Randômico : $w_i = [r(0, 1), r(0, 1), r(0, 1), r(0, 1)]$.



Mapas Auto-Organizáveis de Kohonen: Escolha do Best Match Unit (BMU)


Para cada neurônio j , calcular a
medida de similaridade. Por
exemplo, com distância euclidiana



A menor distância, ou seja, o BMU,
será eleito para ajuste

$$d_j = \sqrt{\sum (x_i - w_i)^2}$$

$$BMU = \max(d)$$



Mapas Auto-Organizáveis de Kohonen: Ajuste de Pesos do BMU

O ajuste do BMU ocorre pelo ajuste do erro calculado com a entrada x




Cada peso é individualmente corrigido conforme os atributos da entrada apresentada



Ajusta os pesos em função do parâmetro η que indica a taxa de aprendizado

$$w_i = w_i + ((x_i - w_i) \cdot \eta)$$



Mapas Auto-Organizáveis de Kohonen: Ajuste de Pesos da Vizinhaça

Para cada linha e coluna (neurônio), calcular r para o BMU

A vizinhaça pode decair conforme as iterações

Taxa θ ajusta conforme a vizinhaça para o BMU


Erro calculado com a entrada x


Ajusta em η , que indica a taxa de aprendizado

$$r = \sqrt{(bmu^{linha} - w^{linha})^2 + (bmu^{coluna} - w^{coluna})^2}$$

$$\theta(bmu, w) = \exp\left[-\frac{r}{2\sigma^2}\right]$$

$$w_i = w_i + (\theta(bmu, w) \cdot (x_i - w_i) \cdot \eta)$$





Mapas Auto-Organizáveis de Kohonen: Ajuste da Taxa de Aprendizizado

T é o total de iterações, k é a iteração atual

Constante

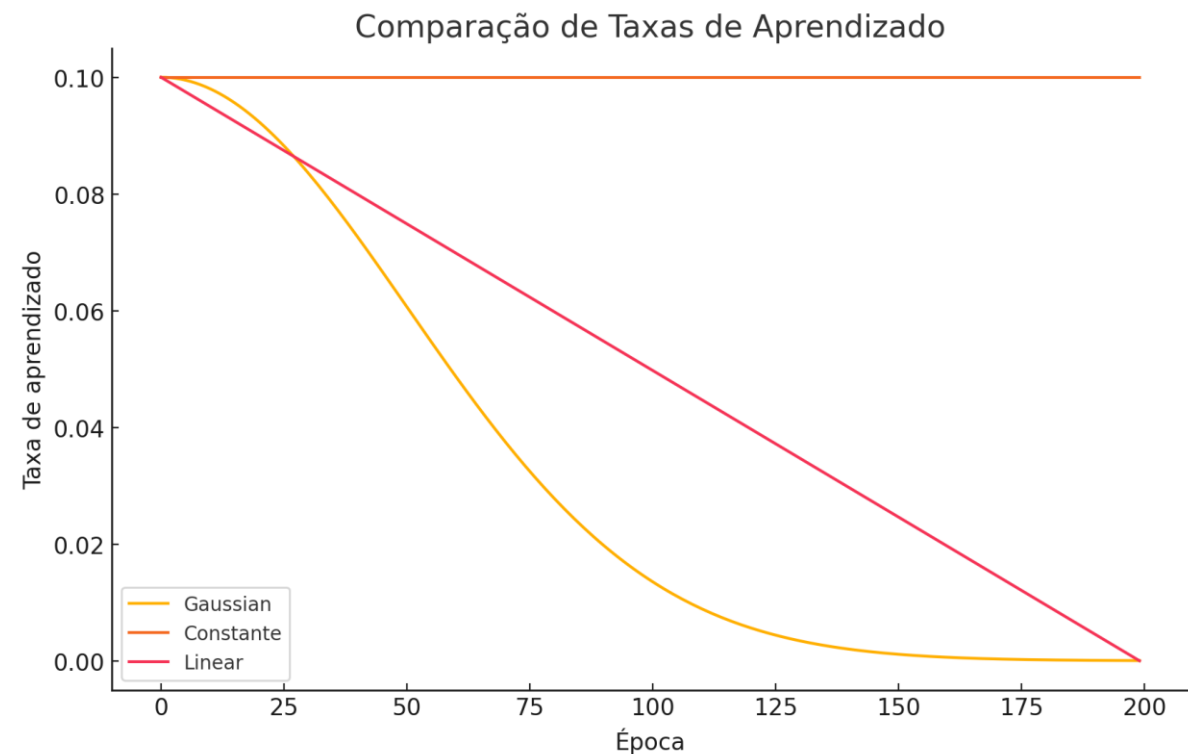
Linear


Não-linear

$$\eta_k = 0.1$$

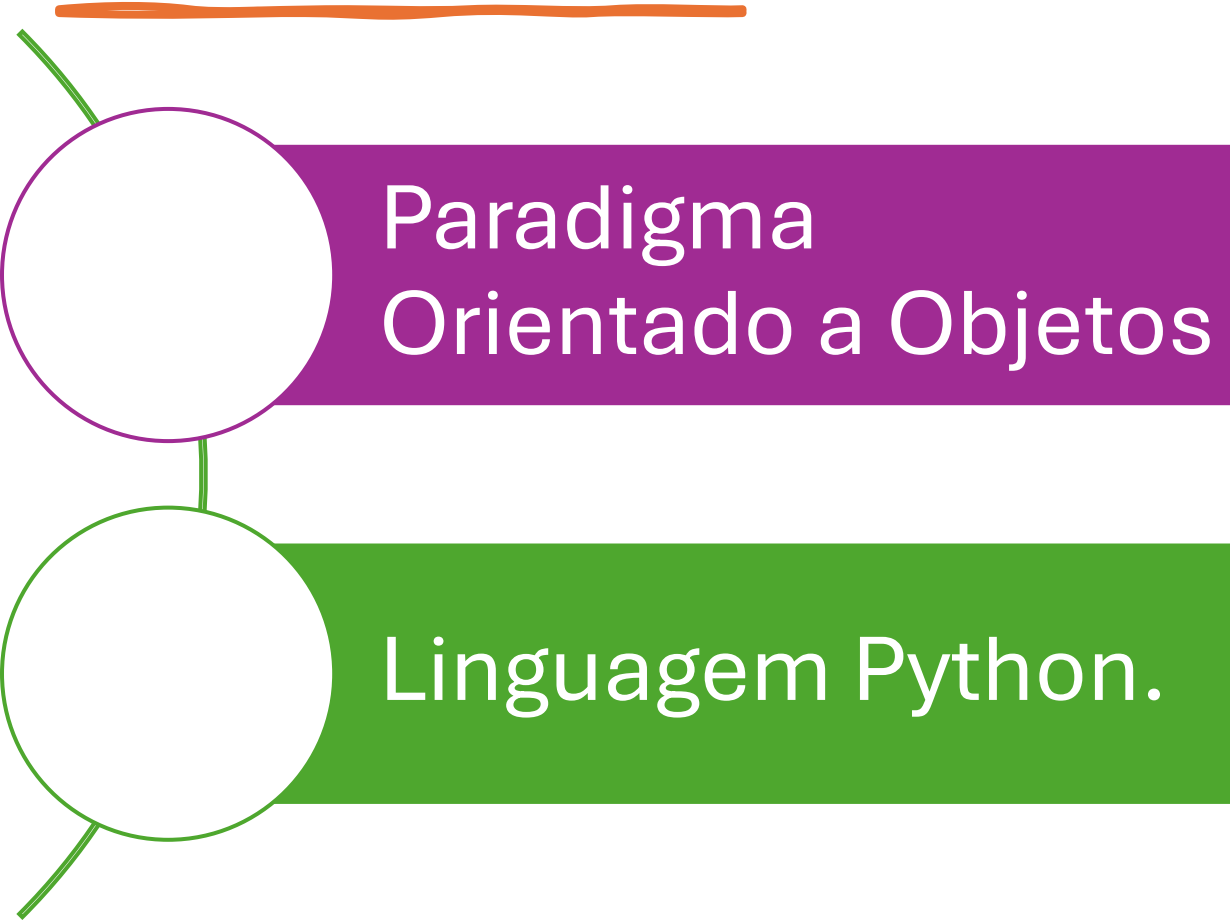
$$\eta_k = \eta_0 - \left(1 - \frac{k}{T}\right)$$

$$\eta_k = \eta_0 \cdot \exp\left[-\frac{k}{\frac{T}{2}}\right]$$






Mapas Auto-Organizáveis de Kohonen : Código



Paradigma
Orientado a Objetos

Linguagem Python.

[https://github.com/pablorange82/
introducao_aprendizado_nao_supervisio
nado](https://github.com/pablorange82/introducao_aprendizado_nao_supervisionado)



**Laboratório de Fusão e
Inteligência Artificial Aplicada
(LaFIAA)**



**Instituto de Pesquisas
da Marinha**

Dúvidas?

pablo.rangel@marinha.mil.br